Violence Image Detection

Kamila Jeannette Martinez Ibarra - A01711833
Inteligencia artificial avanzada para la ciencia de datos (Gpo 601)

Abstract—Resumen del trabajo.

Index Terms—deep learning, redes neuronales convolucionales, detección de violencia, transfer learning

1 Introducción

Los videos e imágenes de diferentes situaciones se han convertido de gran importancia para la administración de la justicia. Hoy en día, la presencia de cámaras de vigilancia y teléfonos celulares hace que una gran parte de los hechos violentos queden grabados en video; sin embargo, las personas que deben revisarlos, como policías, abogados y jueces, están expuestas de forma repetida a contenido que puede generar estrés traumático secundario. En un estudio con 16 profesionales del sistema de justicia en Canadá, los participantes reportaron que el volumen de video ha crecido al grado de crear unidades dedicadas solo a su análisis, en las que una persona puede revisar este material durante ocho horas seguidas [1].

Como alternativa a este problema, los modelos de aprendizaje profundo permiten clasificar de forma automática si una imagen contiene una escena violenta o no. Sin embargo, para que estos sistemas sean útiles, deben identificar correctamente la violencia sin marcar como violentas escenas cotidianas en las que hay contacto entre personas, de forma que reduzcan el material que una persona tiene que revisar sin perder evidencia importante.

1.1 Contexto del Conjunto de Datos

Para este trabajo se utilizan dos conjuntos de datos. El primero es Violence vs. Non-Violence: 11K Images, publicado en Kaggle [2], que contiene 11,073 imágenes de 416 × 416 píxeles clasificadas previamente como violentas y no violentas. Estas imágenes son fotogramas extraídos de los videos del conjunto Real Life Violence Situations, el cual reúne 2,000 videos obtenidos de YouTube: 1,000 de peleas reales en la calle y 1,000 de actividades cotidianas, como comer, caminar o hacer deporte. Este conjunto se utiliza para el entrenamiento y la validación del modelo.

El segundo conjunto contiene 350 videos grabados con actores [3]: 230 con escenas violentas y 120 con escenas no violentas, entre las que se incluyen abrazos y saludos. Cada escena se grabó con dos cámaras distintas, un teléfono celular y una cámara de acción. De cada video se extraen 8 fotogramas, los cuales se utilizan como conjunto de prueba.

Conjunto	No violencia	Violencia	Total
Kaggle	5,231	5,842	11,073
Bianculli	960	1,840	2,800

2 ETL

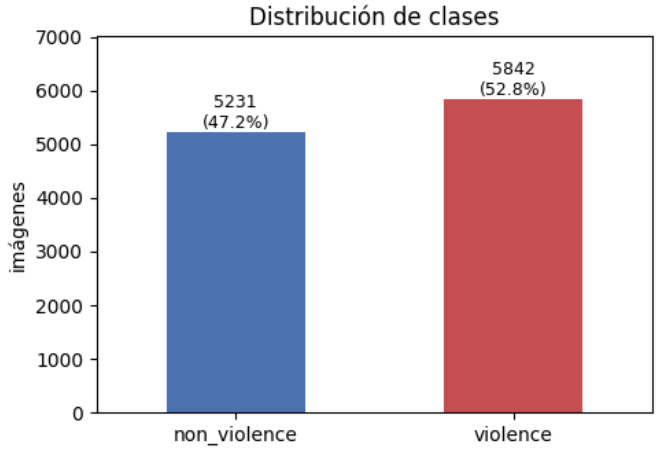
Extracción, transformación y carga (ETL) es el proceso consistente en combinar datos de diferentes orígenes en un gran repositorio central. El proceso consta de tres pasos. Primero se extraen los datos de la fuente origen, seguido de una transformación de estos adecuada al analisis previsto, y finalmente se cargan en un repositorio de datos [4].

2.1 Extracción

El conjunto de datos de Kaggle [2] se descargó con la librería kagglehub de Python. En el caso del conjunto de Bianculli et al. [3], se clonó su repositorio de GitHub y, con la librería OpenCV, se extrajeron 8 fotogramas de cada video, sin incluir el primero ni el último.

2.2 Análisis exploratorio de datos

El conjunto de Kaggle [2] contiene 5,231 imágenes no violentas (47.2%) y 5,842 violentas (52.8%), por lo que presenta un desbalance leve. Todas las imágenes están en formato JPEG, tienen un tamaño de 416 × 416 píxeles en RGB y ninguna está corrupta.



Como las imágenes son fotogramas de videos, se revisó si los archivos con números consecutivos pertenecen al mismo video. Para esto se calculó la diferencia absoluta media entre pares de imágenes en escala de grises de 64 × 64 píxeles. Un valor de 0 indica imágenes idénticas y

valores cercanos a 1 indican imágenes muy distintas. Se compararon 300 pares de imágenes consecutivas contra 300 pares aleatorios por clase. Las distribuciones resultaron casi iguales, con medias de 0.242 y 0.289 en la clase no violenta y de 0.288 y 0.304 en la violenta, por lo que el número de archivo no indica de qué video proviene cada imagen. Sin embargo, al revisar las imágenes, se observó que una misma escena aparece en números cercanos, pero no contiguos, por lo que una partición aleatoria dejaría fotogramas del mismo video en entrenamiento y validación.

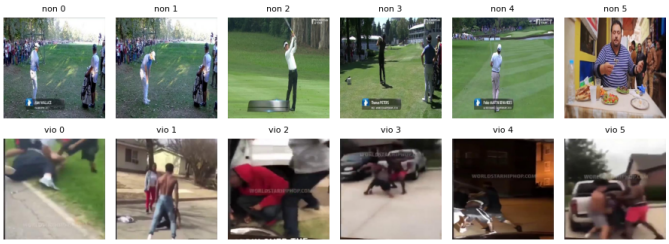


Fig. 1. Imágenes de Kaggle

2.3 Selección de imágenes

Como las imágenes de Kaggle son fotogramas de videos, una partición aleatoria dejaría fotogramas casi idénticos de un mismo video en entrenamiento y en validación. Barz y Denzler [5] muestran que este tipo de duplicados entre subconjuntos hace que la exactitud reportada sea mayor a la real. Para evitar esta fuga de información, se agruparon las imágenes similares antes de hacer la partición.

2.3.1 Embeddings

Un embedding es una representación de un dato como un vector de números, construida de forma que los datos parecidos queden cerca entre sí. En el caso de las imágenes, se pueden obtener a partir de las activaciones de una red neuronal convolucional entrenada previamente: Razavian et al. [6] muestran que estas características, usadas sin volver a entrenar la red, funcionan bien para comparar y reconocer imágenes de distintos dominios.

2.3.2 MobileNetV2

MobileNetV2 [7] es una red neuronal convolucional ligera, diseñada para dispositivos móviles. En este trabajo se utilizó MobileNetV2 preentrenada en ImageNet, sin su capa de clasificación, como extractor de características. Cada imagen se representó con un vector de 1,280 valores, normalizado para poder comparar las imágenes con la similitud coseno:

$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \, \|\mathbf{b}\|} \tag{1}$$

la cual vale 1 cuando dos imágenes son idénticas y se acerca a 0 cuando no tienen relación.

2.3.3 Primer intento: k-means

K-means [8] es un algoritmo de agrupamiento no supervisado que divide los datos en k grupos. Cada dato se asigna al centroide más cercano, después cada centroide se recalcula como el promedio de los datos de su grupo, y estos dos pasos se repiten hasta que las asignaciones dejan de cambiar.

Siguiendo a SemDeDup [9], que agrupa embeddings con k-means para encontrar imágenes duplicadas, se formaron 300 grupos por clase. Para revisar el resultado se siguió el procedimiento de Barz y Denzler [5]: para cada imagen de validación se buscó la imagen más parecida en entrenamiento y se revisaron visualmente los pares más similares. Estos pares, con similitudes entre 0.90 y 0.93, seguían siendo fotogramas del mismo video. Esto se debe a que, cuando la cámara se mueve, la primera mitad del video queda más cerca de un centroide y la segunda mitad de otro, así que el video termina en dos grupos distintos. Como la partición se hace por grupo, una mitad puede ir a entrenamiento y la otra a validación, y eso es justo la fuga que se quería evitar. Por lo tanto, este experimento se declara como fallido.

2.3.4 Segundo intento: componentes conexas

Antes del segundo intento se eliminaron 58 imágenes que se encontraron durante el primer intento: fotogramas oscuros y fotogramas negros repetidos en ambas clases.

Para el segundo intento se cambió la forma de agrupar. En lugar de fijar un número de grupos, se comparó cada imagen con todas las demás y se unieron las que tuvieran una similitud mayor o igual a un umbral τ. Los grupos se forman como una cadena: si la imagen A se parece a B y B se parece a C, las tres quedan en el mismo grupo, aunque A y C no se parezcan tanto entre sí. Así, los fotogramas de un video se mantienen juntos aunque la cámara se mueva, porque cada fotograma se parece al siguiente. A cada uno de estos grupos se le conoce como componente conexa. Se probaron distintos valores de τ (Tabla 1).

Tabla 1
Número de grupos y tamaño del grupo más grande según τ

τ	Grupos	Grupo más grande
0.76	3,057	3.4%
0.75	2,542	12.5%
0.74	2,011	26.5%
0.70	660	79.3%

Mientras más bajo es τ, más imágenes se unen entre sí. Con valores menores a 0.75, el grupo más grande crece muy rápido hasta reunir casi todas las imágenes, mientras que con valores mayores los fotogramas de un mismo video quedan separados en varios grupos. Por eso se eligió $\tau = 0.75$, con el que se obtuvieron 2,542 grupos, un número cercano a los 2,000 videos originales. Al revisar otra vez los pares más parecidos, algunos seguían siendo del mismo video, por lo que la fuga se reduce, pero no desaparece por completo. Por esta razón, la evaluación final se hace con el conjunto de Bianculli [3].

2.4 Transformación

Texto

2.5 Exportación

Texto

3 Subconjuntos

Texto

4 Modelo base - CNN

Texto.

5 Mejoras al modelo

Texto.

6 Resultados

Texto.

7 Conclusión

Texto.

Agradecimientos

Texto.

References

[1] A. Birze, K. Regehr y C. Regehr, "Workplace Trauma in a Digital Age: The Impact of Video Evidence of Violent Crime on Criminal Justice Professionals," *Journal of Interpersonal Violence*, vol. 38, no. 1-2, pp. NP1654–NP1689, 2023. [En línea]. Disponible: https://pmc.ncbi.nlm.nih.gov/articles/PMC9709553/

[2] A. M. Raja, "Violence vs. Non-Violence: 11K Images Dataset," Kaggle. [En línea]. Disponible: https://www.kaggle.com/datasets/abdulmananraja/real-life-violence-situations

[3] M. Bianculli, N. Falcionelli, P. Sernani, S. Tomassini, P. Contardo, M. Lombardi y A. F. Dragoni, "A dataset for automatic violence detection in videos," *Data in Brief*, vol. 33, p. 106587, 2020.

[4] Amazon Web Services, "¿Qué es extracción, transformación y carga (ETL)?," Amazon Web Services, Inc. https://aws.amazon.com/es/what-is/etl/

[5] B. Barz y J. Denzler, "Do We Train on Test Data? Purging CIFAR of Near-Duplicates," *Journal of Imaging*, vol. 6, no. 6, p. 41, 2020.

[6] A. S. Razavian, H. Azizpour, J. Sullivan y S. Carlsson, "CNN Features off-the-shelf: an Astounding Baseline for Recognition," en *Proc. IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2014, pp. 806–813.

[7] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov y L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," en *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018, pp. 4510–4520.

[8] S. Lloyd, "Least squares quantization in PCM," *IEEE Transactions on Information Theory*, vol. 28, no. 2, pp. 129–137, 1982.

[9] A. Abbas, K. Tirumala, D. Simig, S. Ganguli y A. S. Morcos, "SemDeDup: Data-efficient learning at web-scale through semantic deduplication," arXiv:2303.09540, 2023.